

Interpretando KANDY

Tecniche Interpretabili e Neuro-Simboliche su KANDY-easy

Cosimo Borghini

Explainable AI – Elaborato

2026

Struttura del laboratorio

Struttura del laboratorio:

- Esplorazione preliminare di KANDY-easy.
- Costruzione sistema di percezione e modelli interpretabili.
- Valutazione di encoders visivi da utilizzare in CBM.
- Confronto CBM con testa lineare e testa con MLP.

Il dataset KANDY

KANDY-Easy


- 2000 immagini
 - 1000 train
 - 500 validation
 - 500 test
- 20 task binari

Struttura dei task

- Task 0–8: proprietà degli oggetti
- Task 9–19: posizione e relazioni
- Crescente difficoltà concettuale


Esempi di task

Task 0




Triangle vs any.

Task 9



Red triangle on the right.

Task 19




Traffic light.

Obiettivi

Obiettivi dell'analisi:


- Come sono distribuiti gli esempi tra i diversi task?
- Quanto sono bilanciate le due classi a livello globale?
- Quali concetti e proprietà degli oggetti sono maggiormente rappresentati?

Distribuzione dei task




Distribuzione dei task del training set.

Distribuzione delle classi



Distribuzione Globale Training


60% degli esempi è negativo.



Distribuzione Locale Training

Varia tra i task.

Distribuzione dei concetti



Distribuzione Concetti Training Set

Metriche di valutazione

Accuracy

Percentuale di predizioni corrette sul totale.

Precision

Quanti degli esempi classificati come positivi sono realmente positivi.

Recall

Quanti degli esempi realmente positivi vengono riconosciuti.

F1-score

Media armonica tra precision e recall.

Perché non basta l'Accuracy?

Gli esempi negativi sono globalmente più numerosi dei positivi: se un classificatore predicesse sempre la classe negativa raggiungerebbe un'accuracy vicina al 60%.

Utilizziamo quindi l'F1-score per valutare i modelli in modo più equilibrato.

Flusso del modello

Immagine → Percezione → Feature Interpretabili → Classificatore → Task

- Percezione deterministica tramite OpenCV
- Feature interpretabili
 - Feature percettive: forma, colore, dimensione, posizione
 - Feature relazionali tra coppie di oggetti
- Classificatori
 - Logistic Regression
 - Decision Tree
 - Explainable Boosting Machine

Percezione degli oggetti


Colore:

- confronto con i colori del dataset
- assegnazione del colore più vicino
- soglia sulla distanza RGB

Forma e dimensione:

- template triangolo quadrato cerchio
- individuazione dei contorni
- classificazione small / large

Valutazione del sistema percettivo



Individuazione oggetti tramite sistema percettivo.

Risultati

	Train	Val.	Test
MAE count	0.038	0.050	0.046
Count exact	0.963	0.954	0.954
Shape accuracy	0.950	0.966	0.947
Color accuracy	1.000	1.000	1.000
Size accuracy	0.873	0.867	0.871

Osservazione

Il sistema riconosce bene numero, forma e colore degli oggetti, tuttavia ha richiesto il tuning di alcuni parametri.

Feature interpretabili

Feature percettive

- numero di oggetti
- forma
- colore
- dimensione
- posizione

Feature relazionali

- left / right
- above / below
- diagonal
- same shape / color / size
- aligned / close

Classificatori interpretabili

Logistic Regression

Modello lineare in cui i coefficienti mostrano il contributo delle feature alla predizione.

Decision Tree

Decisioni organizzate gerarchicamente tramite soglie sulle feature.

EBM

Permette di osservare il contributo delle singole feature e delle loro interazioni.

Valutazione

Tra Logistic Regression e Decision Tree scegliamo, per ciascun task, il modello migliore.
Per quanto riguarda EBM, ne alleniamo uno diverso per task.

Confronto tra i modelli per task

Feature percettive

Task	Modello	F1
0	Logistic	1.000
1	Logistic	0.947
2	Logistic	0.923
3	Logistic	1.000
4	Logistic	1.000
5	Logistic	1.000
6	Logistic	1.000
7	Logistic	1.000
8	Logistic	1.000
9	Logistic	0.941
10	Logistic	0.875
11	Logistic	0.865
12	Logistic	0.788
13	Tree	0.857
14	Tree	0.700
15	Logistic	0.500
16	Tree	0.900
17	Logistic	0.941
18	Logistic	0.875
19	Tree	0.267

Feature percettive + relazionali

Task	Modello	F1
0	Logistic	1.000
1	Logistic	0.947
2	Logistic	0.923
3	Logistic	1.000
4	Logistic	1.000
5	Logistic	1.000
6	Logistic	1.000
7	Logistic	1.000
8	Logistic	1.000
9	Logistic	0.941
10	Logistic	0.875
11	Logistic	0.833
12	Tree	0.848
13	Logistic	0.971
14	Tree	0.667
15	Logistic	0.381
16	Tree	0.632
17	Logistic	0.941
18	Logistic	0.968
19	Logistic	0.444

Modello cambiato

Performance peggiorata

Logistic = Logistic Regression

Tree = Decision Tree


Risultati dei modelli interpretabili

Rappresentazione	Mean F1	Mean Accuracy
Feature percettive	0.869	0.882
Feature percettive + relazionali	0.869	0.890
Explainable Boosting Machine	0.902	0.918


Risultato principale

L'EBM ottiene la performance media più elevata.

Esempi di interpretabilità




Logistic Regression
Contributi alla decisione.




Decision Tree
Flusso della decisione.

Explainable Boosting Machine



EBM


Curva di contributo della feature.



EBM


Heatmap che mostra interazione feature.

Confronto tra encoder



La ResNet-18 pretrained ottiene il miglior risultato in validation: **F1 = 0.923**.

ResNet-18 sul test set



Prestazioni buone su task semplici, mentre task e più complessi risultano più difficili.


Interpretabilità: Task 0

Task 0: triangle vs any | pred=0, true=1

FN — immagine



Saliency



Vanilla Gradient


Attivazione più localizzata.

Task 0: triangle vs any | pred=0, true=1

FN — immagine




Grad-CAM



Grad-CAM


Attivazione più diffusa.

Interpretabilità: Task 14



Grad-CAM


Maggiore attivazione nella regione destra.



SHAP

Evidenzia maggiormente i due oggetti laterali.

Concept Bottleneck Model



- La ResNet-18 estrae una rappresentazione visiva dell'immagine
- Il **Concept Layer** comprime l'informazione in concetti interpretabili
- La Task Head utilizza i concetti per predire il task

Vocabolario dei concetti

37 concetti interpretabili

- **Attributi di base**
 - forma
 - colore
 - dimensione
- **Proprietà dell'ultimo elemento**
 - forma, colore, dimensione
- **Confronti**
 - stesso colore
 - stessa forma
 - stessa dimensione
- **Relazioni strutturali**
 - stack
 - side-by-side
 - stessa dimensione
- **Strutture e sequenze**
 - triangolo + quadrato
 - due cerchi affiancati
 - colore del semaforo
 - oggetto prima dell'ultimo

Ogni immagine viene rappresentata da un vettore binario di 37 concetti.

Loss combinata

$$\mathcal{L} = \mathcal{L}_{\text{concept}} + 0.25 \mathcal{L}_{\text{task}}$$

Concept loss

BCEWithLogitsLoss

- 37 concetti supervisionati
- tutti i concept logits contribuiscono
- pos_weight per ogni concetto
- concetti rari, peso maggiore
- il peso è limitato superiormente

Task loss

BCEWithLogitsLoss

- selezionato il logit del task_id
- non vengono usati gli altri 19 logits
- pos_weight specifico per ogni task
- il peso compensa lo sbilanciamento tra positivi e negativi

Confronto tra le task head

Testa lineare

Accuracy media	0.808
F1 medio	0.779
F1 medio concetti	0.906
Accuracy con 0% rumore	0.826
Accuracy con 30% rumore	0.586

MLP


Accuracy media	0.902
F1 medio	0.897
F1 medio concetti	0.897
Accuracy con 0% rumore	0.876
Accuracy con 30% rumore	0.638

La testa MLP migliora nettamente la classificazione finale, mentre la qualità del bottleneck concettuale rimane comparabile.

Ablation dei concetti


Testa lineare

Cumulative Concept Ablation



MLP

Cumulative Concept Ablation - CBM MLP



I concetti vengono sostituiti progressivamente per importanza e in ordine casuale.

Impatto degli errori del bottleneck

Testa lineare

Task	Oracle	Predetto
13	0.76	0.68
15	0.68	0.60
16	0.92	0.84
0	0.92	0.88
18	0.96	0.92

$$\text{drop} = \text{Oracle} - \text{Predetto}$$


MLP

Task	Oracle	Predetto
16	0.92	0.84
13	0.92	0.88
15	0.76	0.72
17	0.96	0.92
18	1.00	0.96

$$\text{drop} = \text{Oracle} - \text{Predetto}$$


Per molti task il drop è nullo: la task head riesce quindi a mantenere la stessa performance anche con concetti predetti.

Visualizzazione concetti lineare




Quanto ciascun concetto contribuisce ai task

Visualizzazione concetti lineare



Probabilità assegnate dal bottleneck ai concetti per una specifica immagine

Visualizzazione concetti MLP



Probabilità assegnate dal bottleneck ai concetti per una specifica immagine

Conclusioni

Dataset e rappresentazione

- KANDY-Easy presenta difficoltà crescente tra i task
- i task più complessi richiedono relazioni e combinazioni di proprietà
- lo sbilanciamento rende necessario considerare anche l'F1-score

Modelli interpretabili

- feature percettive sufficienti per molti task
- le relazioni non migliorano necessariamente ogni task

Encoder visivi

- il pretraining è importante con dataset di dimensioni ridotte
- ResNet-18 pretrained selezionata come encoder

Concept Bottleneck Model

- il bottleneck rende esplicita la rappresentazione intermedia
- la testa MLP recupera parte della performance persa con la lineare
- rimangono difficoltà nei concetti più compositivi

Grazie!

Riferimenti bibliografici

- [1] L. S. Lorello, M. Lippi, S. Melacci, *The KANDY benchmark: Incremental neuro-symbolic learning and reasoning with Kandinsky patterns*, Machine Learning, 114, 2025. DOI: 10.1007/s10994-025-06798-x.
- [2] *Note del corso di Explainable Artificial Intelligence.*